Exercícios Transformers

Exercícios teóricos

1. Explique por que a arquitetura Transformer permite uma paralelização significativamente maior durante o treinamento em comparação com Redes Neurais Recorrentes (RNNs), como LSTMs e GRUs.

2. O Transformer não possui recorrência nem convolução. Como o modelo consegue incorporar informação de ordem dos tokens em uma sequência?

3. Qual é a principal vantagem de utilizar atenção *multi-head* em vez de um único mecanismo de atenção?

4. Qual é o objetivo da auto-atenção mascarada (*masked self-attention*) no decoder?

5. Explique o papel das conexões residuais e da normalização de camada (*Layer Normalization*) em um bloco Transformer.

Cálculo de Atenção Escalonada (Scaled Dot-Product Attention)

Considere um cenário simplificado com uma sequência de 2 tokens. A dimensão das chaves é $d_k = 4$.

Vetores

$$q_1 = 3$$

$$k_1 = 3, \quad k_2 = 3$$

$$v_1 = 4, \quad v_2 = 5$$

Responda as questões a seguir:

1. Calcule o produto escalar entre q_1 e cada chave.

2. Aplique o escalonamento dividindo os resultados por $\sqrt{d_k}$.

3. Aplique a função softmax sobre os valores escalonados e obtenha os pesos de atenção.

4. Calcule a saída final a_1 realizando a soma ponderada dos valores.

Fluxo de Processamento em um Bloco Transformer

Considere uma sequência com $N = 10$ tokens, $d_{model} = 512$ e $d_{ff} = 2048$. A entrada do bloco é uma matriz $X \in \mathbb{R}^{10\times512}$. Responda as questões a seguir:

1. O que acontece quando X passa pela subcamada de Multi-Head Attention? Qual é a dimensão da saída?

2. Como ocorre a soma residual e a aplicação da LayerNorm após a atenção?

3. Descreva a transformação de dimensão dentro da Feed-Forward Network.

4. Qual é a dimensão da saída final do bloco?

Cálculo de Parâmetros em Camadas Transformer

Considere a camada de atenção abaixo e responda as questões a seguir:

- $d_{model} = 512$
- 8 cabeças de atenção

1. Quantos parâmetros existem nas projeções lineares de Query, Key e Value?

2. Quantos parâmetros existem na projeção final da saída da atenção?