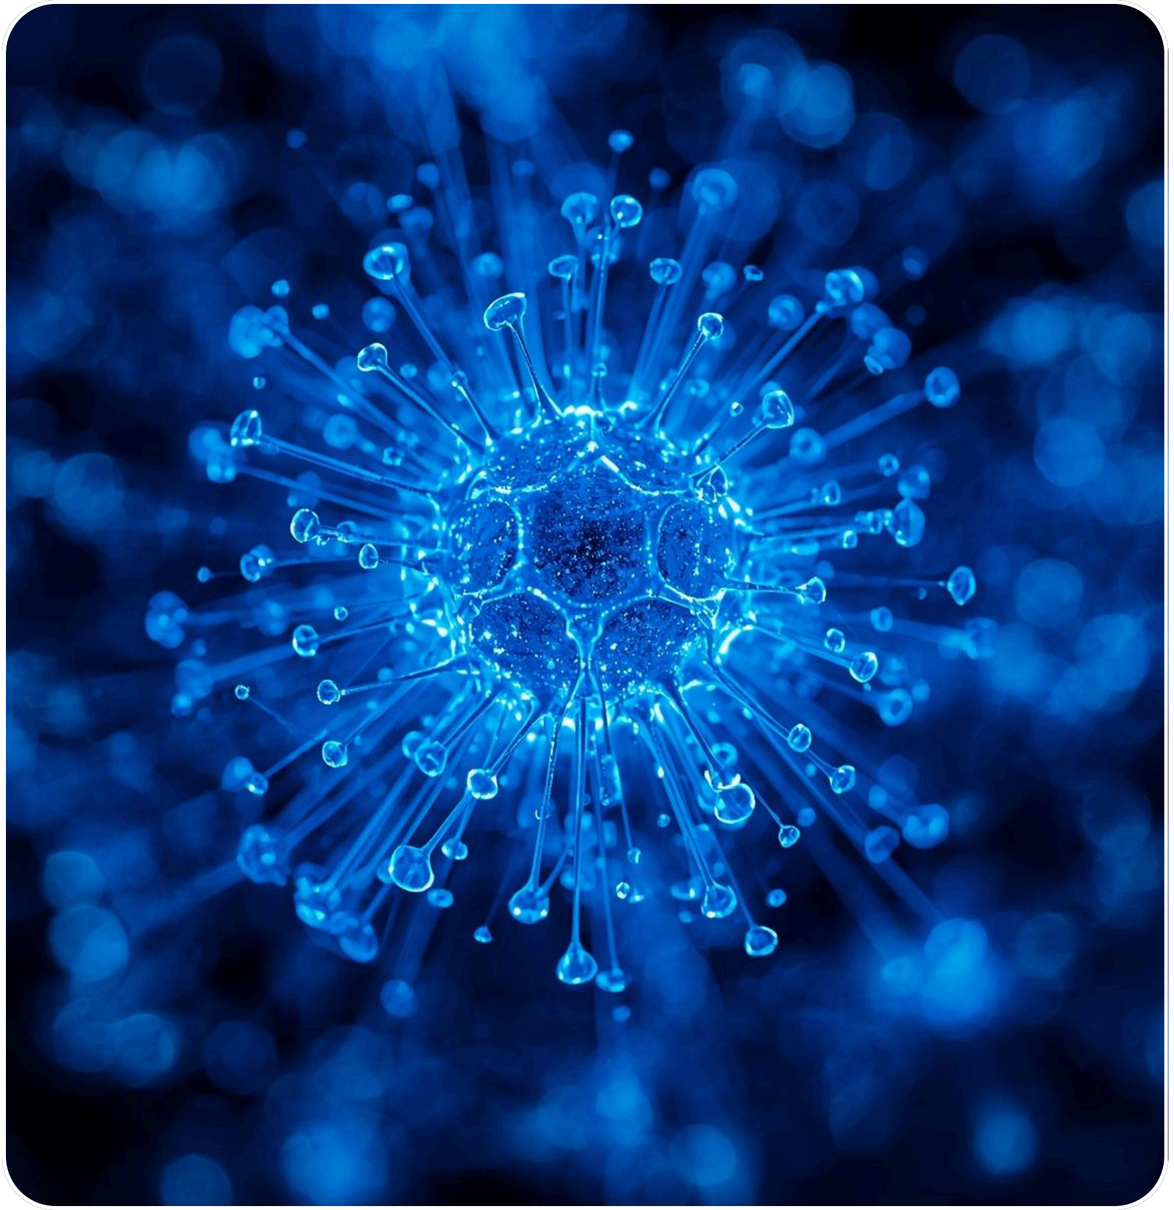


Síntese de Imagens em Alta Resolução com Modelos de Difusão Latente

Integrantes

- João Pedro Costa Baroni - 12311BCC035
- Leonardo Henrique Carvalho Oliveira - 12311BCC003
- Matheus Henrique Barbosa Ribeiro - 12311BCC041
- Rodrigo Otávio Fernandes Rodrigues - 12311BCC008
- Yan Lucas Santos Marra - 12311BCC013

Sumário

1. Introdução sobre o problema
2. Objetivos e contribuições do artigo
3. Método
4. Experimentos
5. Conclusão

Introdução sobre o problema

- **Síntese de imagens**: Modelos de Difusão (DMs) superam GANs (Redes Adversariais Gerativas) em estabilidade e qualidade.
- Funcionam como uma hierarquia de denoising autoencoders (removedores de ruído).
- DMs tradicionais operam diretamente no Espaço de Pixel.
- Gastam recursos excessivos modelando detalhes de alta frequência que são imperceptíveis ao olho humano.

Introdução sobre o problema

- Otimizar modelos poderosos requer centenas de dias de GPU.
- A geração é cara e lenta devido às avaliações sequenciais.
- **Gargalo**: gasta-se muita energia em compressão perceptual (detalhes finos) e menos na compressão semântica (o conteúdo da imagem).
- DMs são poderosos, mas computacionalmente inviáveis no espaço de pixel (elevado custo computacional).

Objetivos

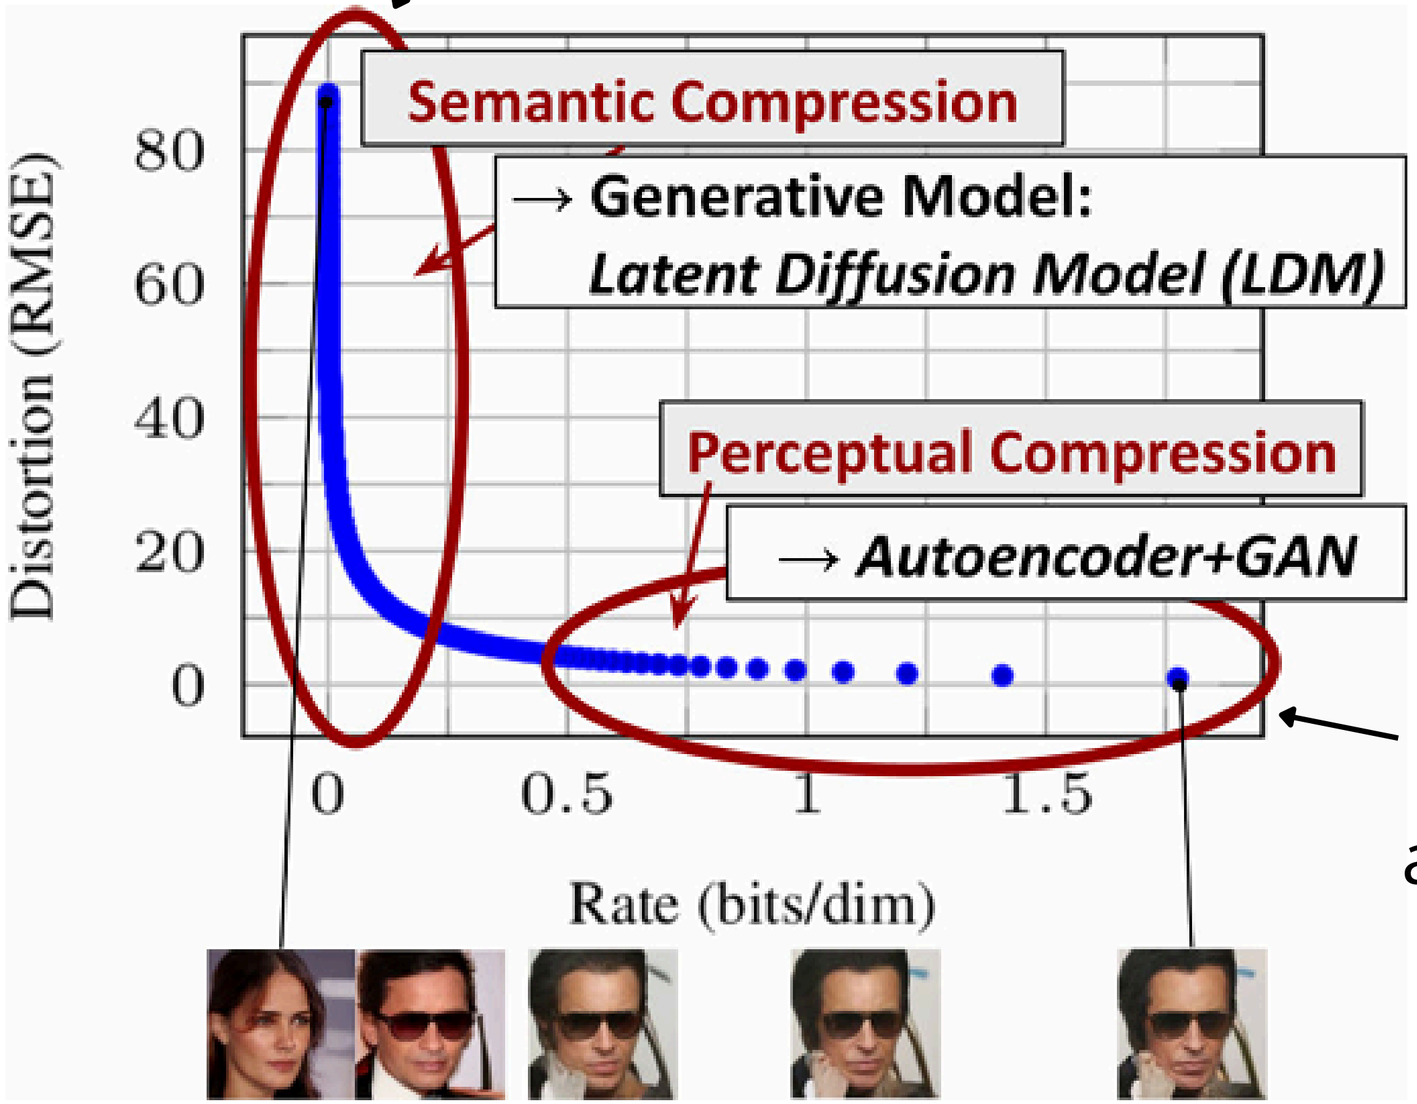
- **Democratizar a Síntese de Alta Resolução:** Permitir o treino de modelos de difusão em recursos computacionais limitados sem sacrificar a qualidade ou a flexibilidade.

- **Equilíbrio Ótimo:** Encontrar um espaço que seja computacionalmente eficiente, mas equivalente ao espaço de dados, evitando a perda de detalhes finos.

Contribuições

- Criação dos Latent Diffusion Models (LDMs), que operam num espaço comprimido eficiente.
- Divisão do trabalho:
- Um Autoencoder cuida da compressão perceptual (remove o que é imperceptível).
- O Modelo de Difusão foca exclusivamente na compressão semântica (o espaço latente).

Onde está o conteúdo real da imagem e onde o modelo aprende a estrutura da imagem



Mostra que a maioria dos bits em uma imagem serve apenas para corrigir detalhes minúsculos e imperceptíveis

Contribuições

- **Eficiência e Escalabilidade:** O método escala graciosamente para altas resoluções, oferecendo reconstruções mais fiéis com menor custo computacional.

- **Mecanismo de Atenção Cruzada (Cross-Attention):** Introdução de uma arquitetura flexível que permite condicionar a geração de imagens em várias modalidades (texto-para-imagem e layout-para-imagem).

Contribuições

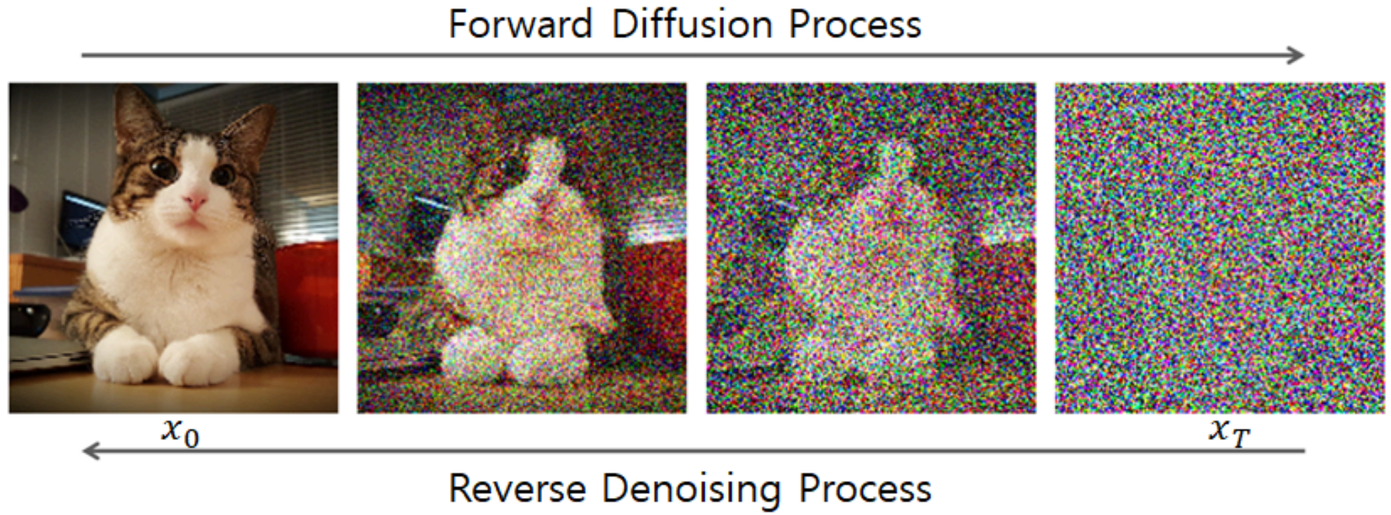
- **Versatilidade de Tarefas:** Obtenção de resultados competitivos ou Estado da Arte em diversas tarefas: inpainting (restauração/preenchimento), geração de imagem incondicional, super-resolução e síntese texto-para-imagem.

- **Modelos Pré-treinados:** Disponibilização de modelos universais de autoencoding e difusão para a comunidade reutilizar em diferentes tarefas (precisamos treinar o estágio de autoencoding universal apenas uma vez).

Método

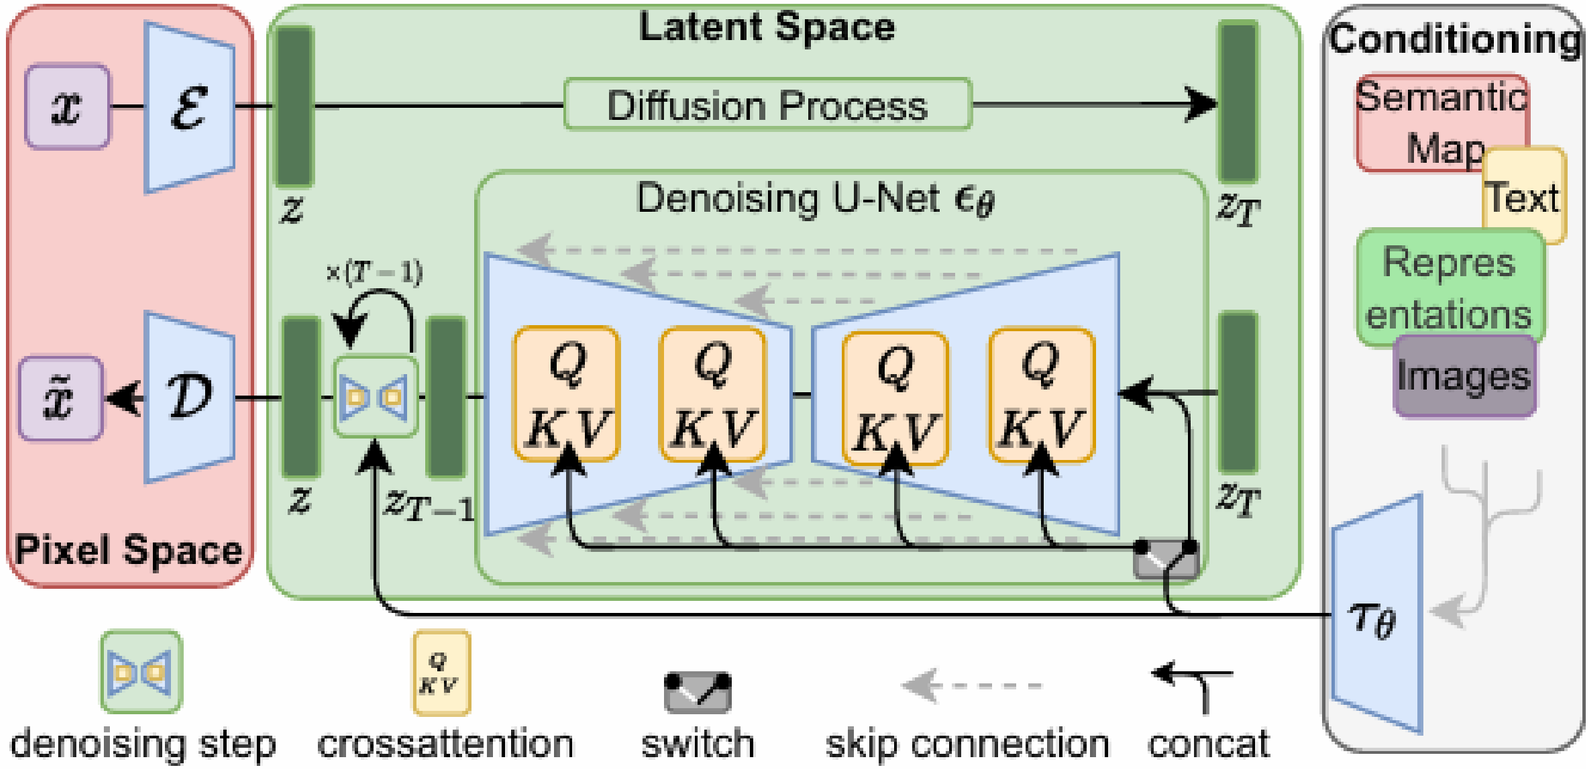
Funcionamento Modelo de Difusão clássico

- **Definição**: "Modelos de difusão são modelos geradores que aprendem a criar imagens revertendo um processo de ruído.
- Como funciona:
- **Forward (Ida)**: O modelo pega uma imagem e adiciona ruído gradualmente até ela ser totalmente destruída.
- **Reverse (Volta)**: Treinamos uma rede neural para aprender a remover esse ruído passo a passo.



Método

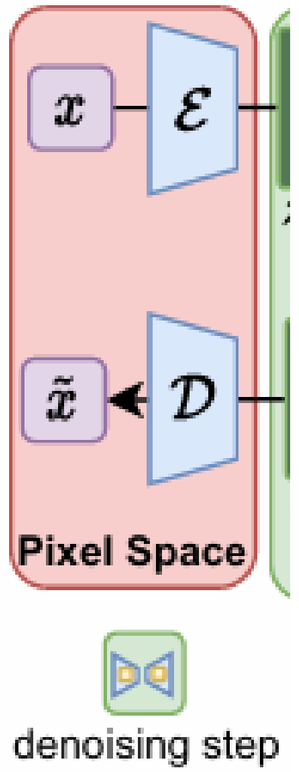
Visão Geral da Arquitetura do Modelo de Difusão Latente (O Mapa)



Método

Compressão Perceptual (O Autoencoder)

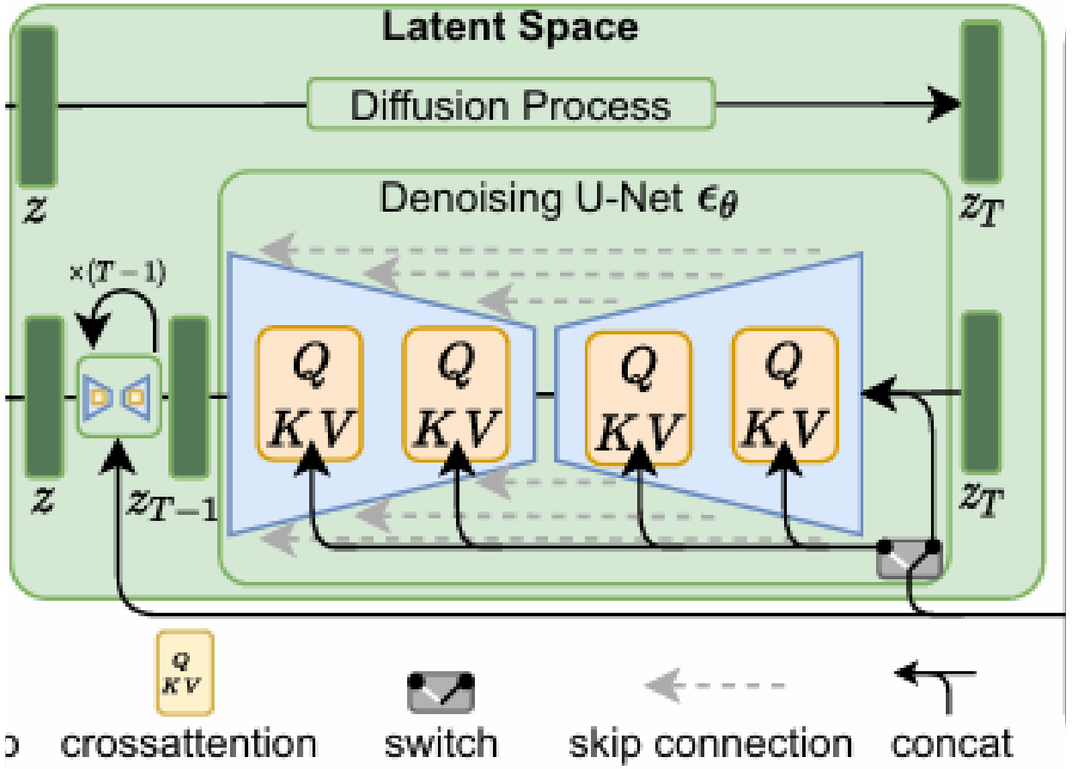
- **Separação em duas fases:** Treinamento do Autoencoder e Treinamento da Difusão.
- **Encoder**: Transforma a imagem x em uma representação latente z =E(x).Funções:Perda Perceptual: Que garante que as formas e bordas sejam preservadas.
- **Perda Adversária**: Que força a geração de texturas nítidas e realistas.
- **Fator de Downsampling (f)**: A imagem é reduzida por um fator f (ex: f=4 ou 8), tornando o espaço latente muito mais leve que os pixels.
- **Regularização**: Uso de KL-penalty ou Vector Quantization (VQ) para evitar alta variância no espaço latente.



Método

Latent Diffusion Models

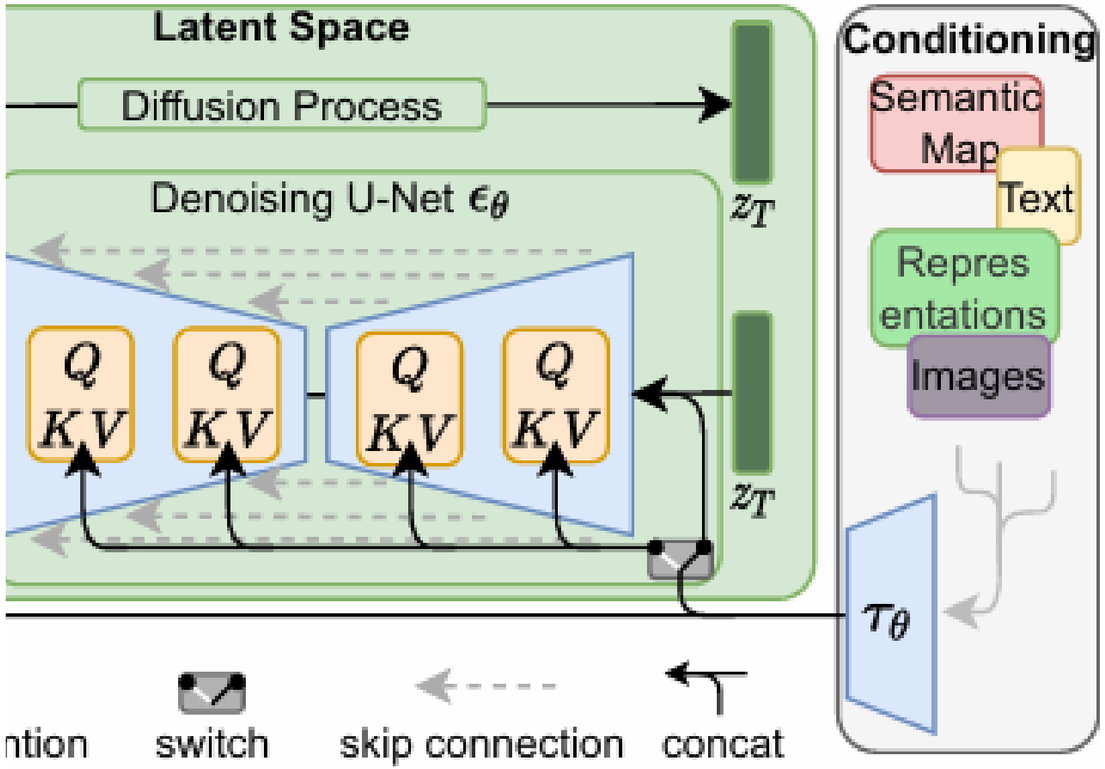
- A difusão ocorre no espaço latente z, não nos pixels.
- **Backbone**: Uma rede Time-Conditional U-Net (Eo) processa os vetores latentes ruidosos.
- **Objetivo**: A rede aprende a predizer o ruído adicionado. A Loss Function (LDM) calcula a diferença entre o ruído real e o predito.
- **Vantagem**: Foca nos dados semânticos importantes e roda com menor custo computacional.



Método

Condicionamento (Cross-Attention)

- Permite controlar a síntese com inputs y (texto, layouts, etc).
- **Domain Specific Encoder**: Processa o input (ex: BERT para texto) para uma representação intermediária.
- **Cross-Attention**: Camadas de atenção integram o condicionamento à U-Net.
- **Q(Query)**: Vem da U-Net (imagem).
- **K, V (Key, Value)**: Vêm do condicionamento (texto).



Experimentos

- **Proposta dos LDMs:** Oferecem síntese de imagem flexível, computacionalmente tratável e de alta resolução em várias modalidades.

- **A Regularização VQ:** Modelos treinados em espaços latentes com Quantização Vetorial (VQ) geram amostras de qualidade superior**.** Isso ocorre mesmo que a capacidade de reconstrução (estágio 1) seja ligeiramente inferior à dos modelos contínuos.

- **Decisão Metodológica:** Devido à qualidade superior das amostras, adotou-se LDMs regularizados por VQ para o restante dos experimentos.

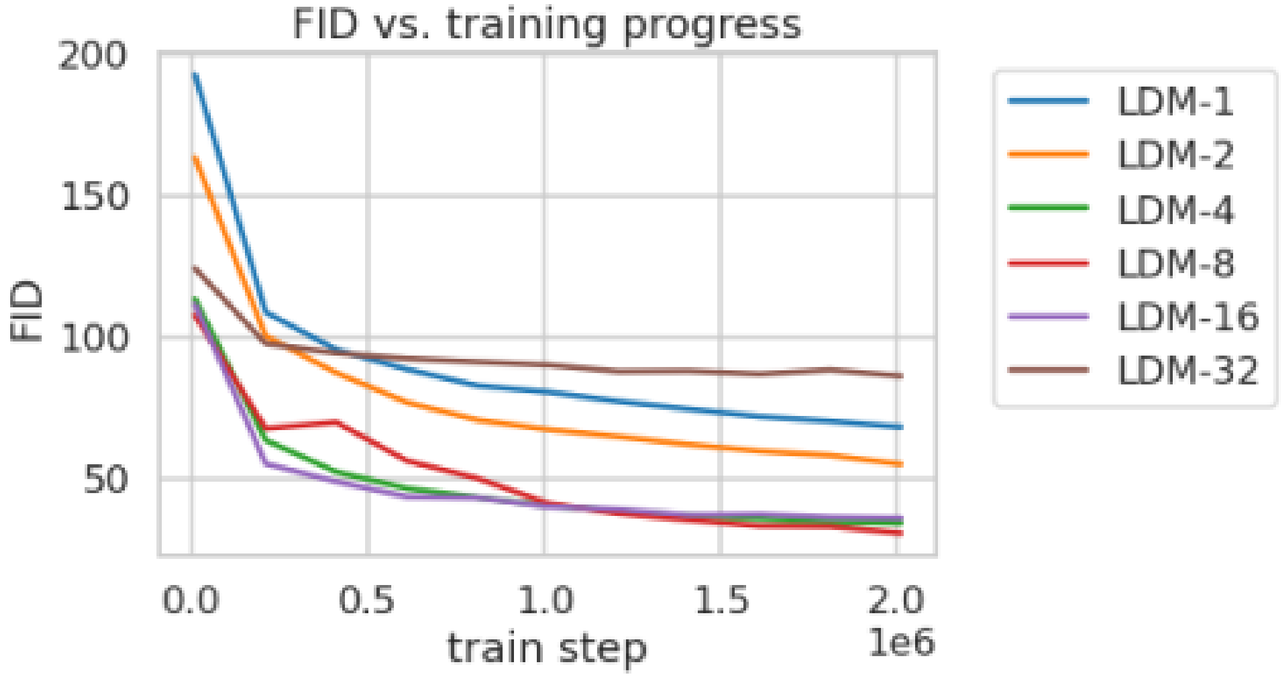
Compensações na Compressão Perceptual

- **O Experimento:** Foram realizados testes com diferentes fatores de redução (f = {1, 2, 4, 8, 16, 32}).
- **Sem Redução:** Para f = 1 é o modelo baseado em pixels (modelo antigo).
- **Padronização:** Para garantir uma comparação justa, todos os modelos foram treinados com os mesmos recursos computacionais (uma única NVIDIA A100) e o mesmo número de etapas e quantidade de parâmetros.

Compensações na Compressão Perceptual

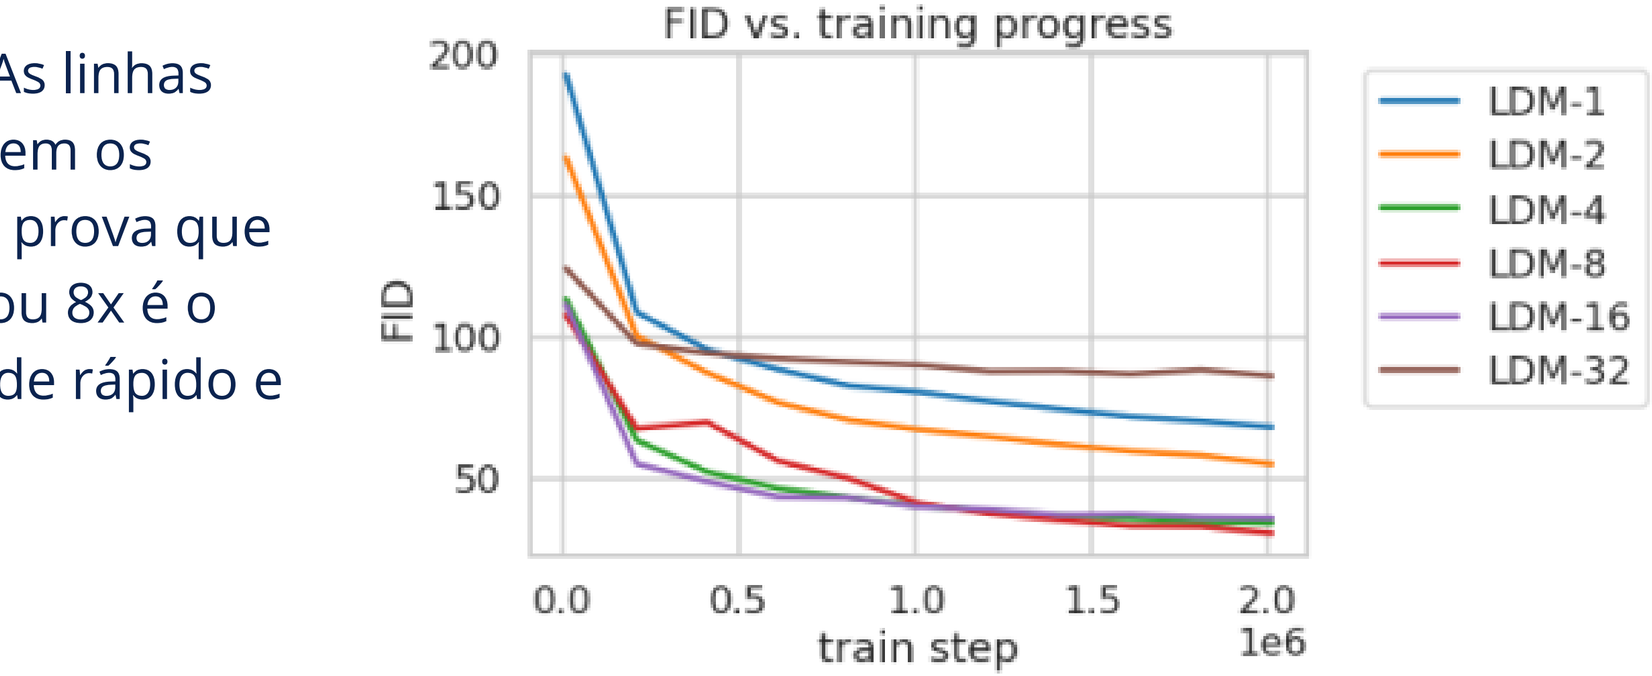
- **O Mínimo:** A linha azul(f = 1) começa no alto e demora para descer. Isso mostra que treinar nos pixels é ineficiente; o modelo demora para aprender a gerar imagens boas.

- **O Máximo:** A linha marrom desce rápido no começo, mas depois estagna. Isso ocorreu porque a compressão excessiva das imagens remove detalhes cruciais, tornando impossível novos avanços no treinamento.



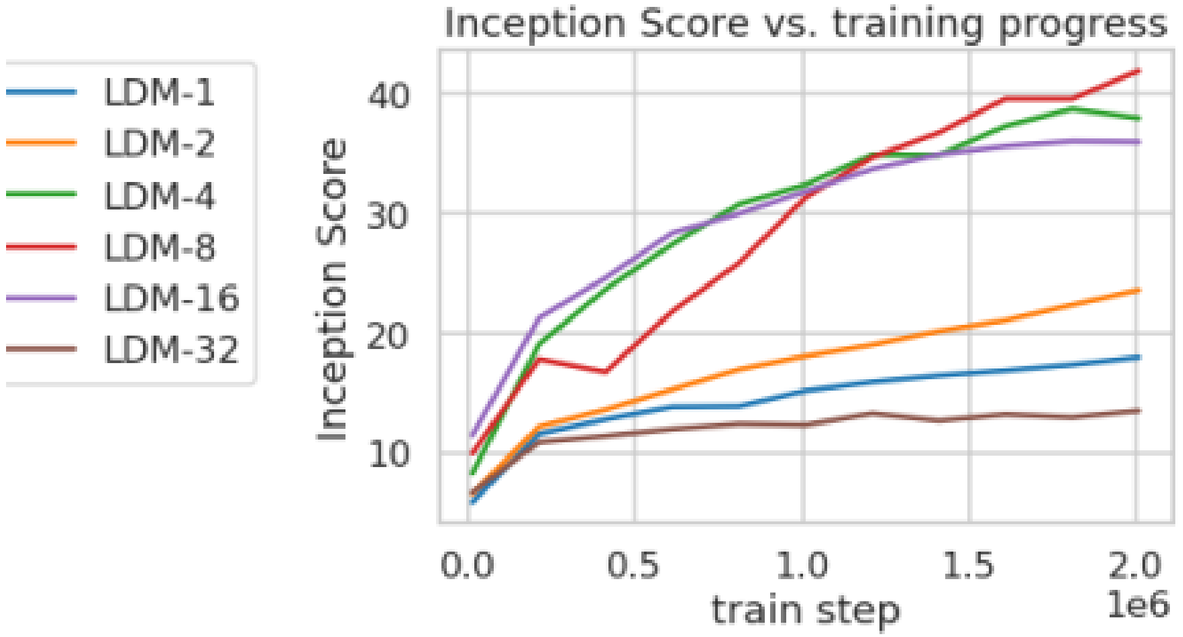
Compensações na Compressão Perceptual

- **Os Campeões(f = 4 e f = 8):** As linhas descem muito rápido e atingem os menores valores de FID. Isso prova que comprimir a imagem em 4x ou 8x é o ponto ideal: o modelo aprende rápido e gera imagens melhores.



Compensações na Compressão Perceptual

- **Os Campeões(f = 4 e f = 8):** O Inception Score mostra a qualidade aumentando das cores vencedoras.



Geração de Imagens com Difusão Latente

- **Recorde (SOTA):** FID de 5.11 no CelebA-HQ
- **Superioridade**: Supera o GANs(PGGAN) e modelos complexos(LSGM).
- **Simplicidade e Estabilidade:** Alta performance usando espaço latente fixo.

CelebA-HQ 256 × 256			
Method	FID ↓	Prec. ↑	Recall ↑
DC-VAE [61]	15.8	-	-
VQGAN+T. [23] (k=400)	10.2	-	-
PGGAN [38]	8.0	-	-
LSGM [90]	7.22	-	-
UDM [42]	<u>7.16</u>	-	-
LDM-4 (ours, 500-s†)	**5.11**	0.72	0.49

Geração de Imagens com Difusão Latente

- **Eficiência:** Qualidade similar ao ADM, mas com metade dos parâmetros e 4x menos treino.
- **Diversidade**: Supera GANs em Precision/Recall, cobrindo melhor a variedade de dados e evitando repetições.

LSUN-Bedrooms 256 × 256			
Method	FID ↓	Prec. ↑	Recall ↑
ImageBART [21]	5.51	-	-
DDPM [29]	4.9	-	-
UDM [42]	4.57	-	-
StyleGAN [40]	2.35	0.59	0.48
ADM [15]	1.90	**0.66**	**0.51**
ProjectedGAN [74]	**1.52**	0.61	0.34
LDM-4 (ours, 200-s)	2.95	**0.66**	0.48

Difusão Latente Condicional

Codificadores Transformer para LDMs: texto-para-imagem

- **Configuração:** Para texto, eles implementam $\tau\theta$ como um Transformer para inferir um código latente para dentro da UNet
- **Treinamento:** Modelo de 1.45 bilhões de parâmetros treinado no dataset LAION-400M.



Figure 7. *Top:* Samples from our *LDM* for layout-to-image synthesis on COCO [4]. Quantitative evaluation in the supplement. *Bottom:* Samples from our text-to-image *LDM* model for user-defined text prompts, which is trained on LAION-400M [76].

- No dataset MS-COCO, superou métodos baseados em GANs e Autoregressivos (AR) poderosos.

Difusão Latente Condicional

Layout-to-Image e Class-Conditional

- **Layouts**: O modelo também pode ser treinado para sintetizar imagens baseadas em layouts semânticos (ex: caixas delimitadoras de objetos) no dataset OpenImages e COCO.

- **ImageNet (Classes):** Comparando com o estado da arte anterior (ADM), o LDM superou a performance usando significativamente menos recursos computacionais e menos parâmetros além de melhorar o FID (qualidade) mantendo a eficiência.



Method	FID↓	IS↑	Precision↑	Recall↑	Nparams
BigGan-deep [3]	6.95	203.6±2.6	**0.87**	0.28	340M
ADM [15]	10.94	100.98	0.69	**0.63**	554M
ADM-G [15]	4.59	186.7	0.82	0.52	608M
LDM-4 (ours)	10.56	103.49±1.24	0.71	0.62	400M
LDM-4-G (ours)	**3.60**	**247.67**±5.59	**0.87**	0.48	400M

Difusão Latente Condicional

Amostragem Convolucional Além de 256^2:

Gerando imagens gigantes (megapixels)

- **O problema:** Normalmente, modelos são limitados à resolução em que foram treinados.
- **A solução do LDM:** Por usar uma arquitetura convolucional, o modelo pode gerar imagens muito maiores que as do treino (ex: treinado em 256^2, gerando em 1024^2 ou megapixels).
- **Aplicação:** Síntese semântica de paisagens. Eles concatenam versões do mapa semântico com a representação latente da imagem resultando em imagens grandes e consistentes, criadas de forma "deslizante" (convolucional).



Figure 8. A *LDM* trained on 256^2 resolution can generalize to larger resolution (here: 512×1024) for spatially conditioned tasks such as semantic synthesis of landscape images. See Sec. 4.3.2.

Difusão Latente Condicional

Super-Resolução com Difusão Latente:
Melhorando a qualidade de imagens existentes.

- Aumentar a resolução de uma imagem pequena (Upscaling 4x).
- Em vez de cross-attention, usa-se concatenação direta. A imagem de baixa resolução é inserida direto na entrada da UNet.
- O LDM-SR supera o modelo concorrente SR3 em FID (texturas mais realistas).
- O SR3 ganha em IS e PSNR (estruturas finas), mas PSNR nem sempre reflete a preferência humana (favorece imagens borradas).

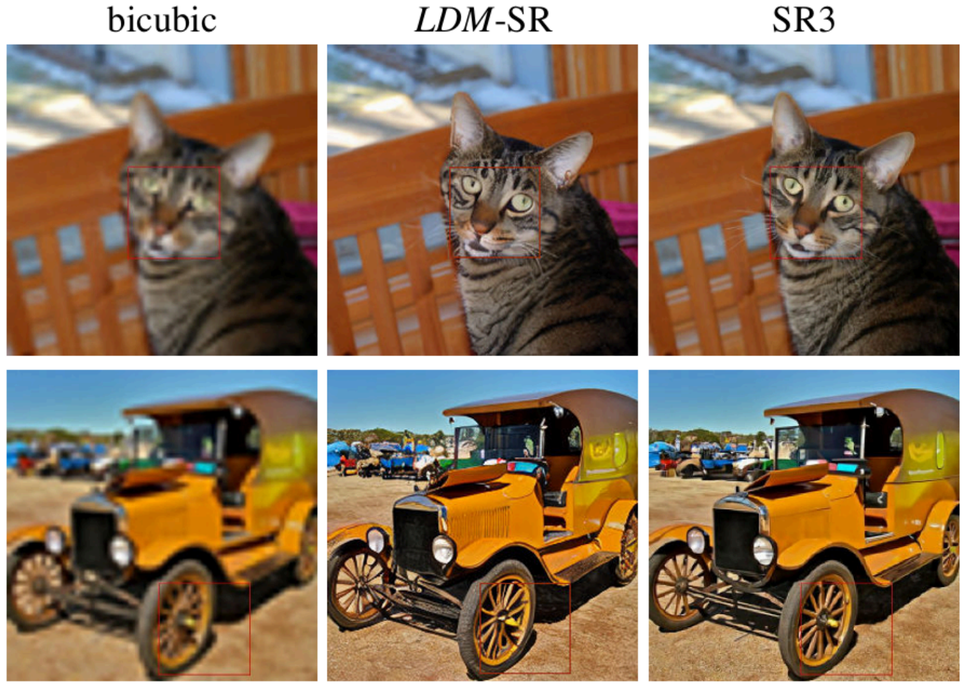


Figure 9. ImageNet 64→256 super-resolution on ImageNet-Val. *LDM-SR* has advantages at rendering realistic textures but SR3 can synthesize more coherent fine structures. See appendix for additional samples and cropouts. SR3 results from [70].

Difusão Latente Condicional

Inpainting com Difusão Latente

- **Inpainting**: Preencher regiões mascaradas com novo conteúdo.
- **LaMa**: Modelo recente de Inpainting com arquitetura especializada baseada em Convoluções Rápidas de Fourier

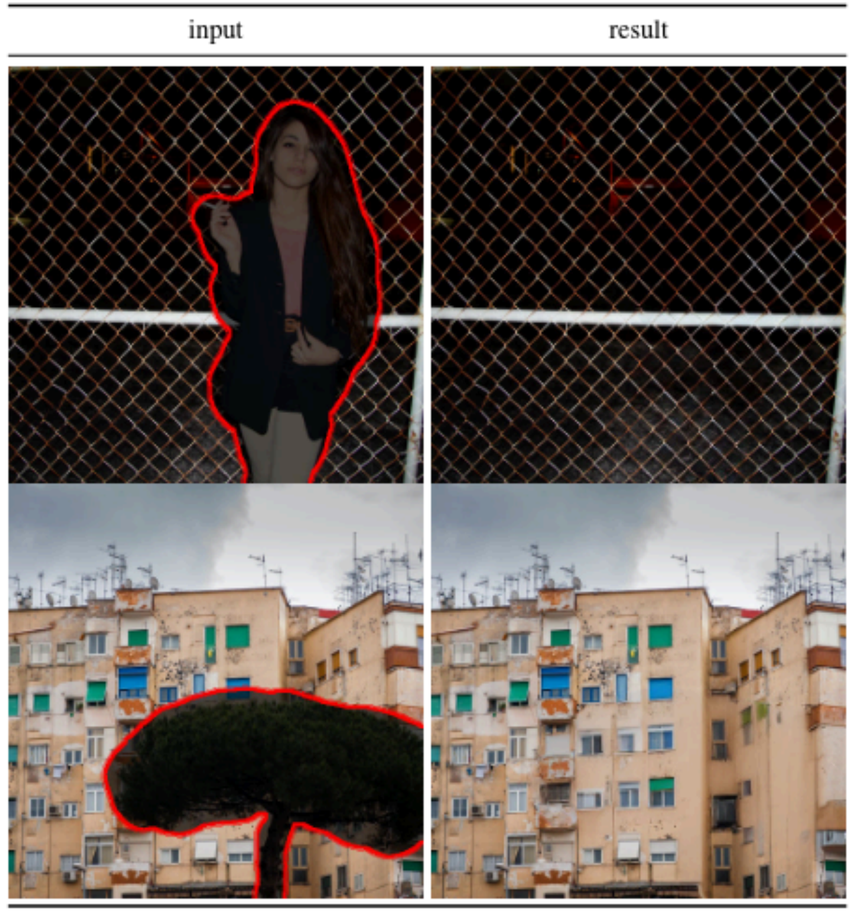


Figure 10. Qualitative results on object removal with our *big, w/ ft* inpainting model. For more results, see Fig. 21.

Difusão Latente Condicional

Inpainting com Difusão Latente

- O modelo em espaço latente (LDM-4) é superior em todos os aspectos em relação ao modelo baseado em pixel (LDM-1).
- LDM-4 usa autoencoder.
- Treinamento e amostragem 2.7x mais rápido no LDM-4 e qualidade (FID) 1.6x melhor.

Model (*reg.*-type)	train throughput samples/sec.	sampling throughput† @256	@512	train+val hours/epoch	FID@2k epoch 6
LDM-1 (no first stage)	0.11	0.26	0.07	20.66	24.74
LDM-4 (*KL*, w/ attn)	0.32	0.97	0.34	7.66	15.21
LDM-4 (*VQ*, w/ attn)	0.33	0.97	0.34	7.04	14.99
LDM-4 (*VQ*, w/o attn)	0.35	0.99	0.36	6.66	15.95

Table 6. Assessing inpainting efficiency. †: Deviations from Fig. 6 due to varying GPU settings/batch sizes *cf*. the supplement.

Difusão Latente Condicional

Inpainting com Difusão Latente

- **Comparação com LaMa:** LDM é superior em qualidade e é visualmente preferível (apesar da métrica LPIPS com menor pontuação).
- **Modelo Big:** Possui 387M de parâmetros ao invés dos 215M.
- **Problema:** Queda de qualidade com 512 pixels.
- **Solução:** Fine-tuning, resultando em um novo Estado da Arte em qualidade.

	40-50% masked		All samples	
Method	FID ↓	LPIPS ↓	FID ↓	LPIPS ↓
LDM-4 (ours, big, w/ ft)	**9.39**	0.246± 0.042	**1.50**	0.137± 0.080
LDM-4 (ours, big, w/o ft)	12.89	0.257± 0.047	2.40	0.142± 0.085
LDM-4 (ours, w/ attn)	11.87	0.257± 0.042	2.15	0.144± 0.084
LDM-4 (ours, w/o attn)	12.60	0.259± 0.041	2.37	0.145± 0.084
LaMa [85]†	12.31	**0.243**± 0.038	2.23	**0.134**± 0.080
LaMa [85]	12.0	**0.24**	2.21	0.14
CoModGAN [103]	10.4	0.26	1.82	0.15
RegionWise [51]	21.3	0.27	4.75	0.15
DeepFill v2 [100]	22.1	0.28	5.20	0.16
EdgeConnect [57]	30.5	0.28	8.37	0.16

Conclusão

- LDMs resolvem o gargalo computacional.
- As LDMs provam que é possível treinar modelos de difusão em espaço latente sem perder qualidade.
- O cross-attention tornou a arquitetura muito flexível da LDM, permitindo uma única arquitetura fazer super-resolução, inpainting e geração de texto para imagens.

Referências

- Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, Bjorn Ommer. *High-Resolution Image Synthesis with Latent Diffusion Models*

Obrigado!

